פרויקט גמר - תיעוד תהליך העבודה והניתוח

פייתון - pandas

בחלק זה של העבודה התבקשתי להוסיף לסכמת stg טבלה שתקרא department_budget אשר תכיל את שם המחלקה, מזהה המחלקה ותקציבה.

תחילה שלפתי את הנתונים מתוך קבצי הtxt כאשר אחד בפורמט csv והשניים האחרים json.
הקבצים היו מחולקים לקובץ שהראה את מזהה המחלקות ושמותיהן, קובץ אשר הראה את תתי המחלקות ותקציבן של מחלקות מספר 1, 2 וקובץ נוסף אשר הראה אותו דבר עבור מחלקה מספר 3.

כדי להגיע לטבלה הרצויה איחדתי בין הטבלאות באמצעות פקודות concat, merge ולבסוף פקודת group by יחד עם סכימה של תקציבי המחלקות כדי לקבל את הטבלה הסופית שאותה העברתי לסכמה המבוקשת באמצעות פקודת to_sql.

api currencies

מטרת החלק הזה הייתה להציג ערכי סכומים המופיעים בdatabase בדולרים בתור תוצאות בשקלים חדשים, לכן נעזרתי באתר המספק את המידע על שערי מטבעות שונים לפי תאריכים ושמו - frankfurter.

השלב הראשון היה לשלוף מתוך סכמת stg באמצעות פקודת read_sql
את תאריכי הקבלות הייחודיים כלומר שכל תאריך מופיע פעם אחת בלבד, לאחר מכן בדקתי שהעמודה של תאריכים הקבלות אכן בפורמט של תאריך בכדי שאוכל ליצור שני משתנים שיהיו תאריך ההתחלה והתאריך האחרון באמצעות פקודות מינימום ומקסימום min, max בהתאמה.
את המשתנים הללו הכנסתי כחלק מה-url אשר שולף את הנתונים מתוך האתר שציינתי קודם ובכך קיבלתי טבלה ובה יחס ההמרה מדולר אמריקאי לשקל חדש.

את הטבלה העברתי לסכמת stg באמצעות הפקודה to_sql.

dwh - sql

החלק הראשון בסכמת dwh היה ליצור אותה ובתוכה טבלאות שהמידע שהן מכילות לקוח מתוך סכמת stg תוך יישום הדרישות עבור הסכמה החדשה.
את כלל הטבלאות בניתי באמצעות פקודת create table as select.

dim_currency

הטבלה נבנתה מתוך stg.currency לאחר בדיקה של תאריכי הקבלות כדי לשלול כפילויות כאשר הטבלה החדשה מכילה את כלל הטבלה stg.currency

dim_playlist

כדי ליצור את הטבלה השתמשתי בinner join בין טבלת playlisttrack לבין טבלת playlist על פי playlistid בחרתי ב-inner כדי לשמור בטבלת dim_playlist רק פלייליסטים שיש להם שירים משויכים.
בבדיקה שביצעתי באמצעות right joib נמצאו פלייליסטים שאין להם שירים משויכים ובנוסף גם ללא מזהה פלייליסט ומכיוון שהטבלה נבנת על הקשר בין playlist id לבין track id רשומות אלו אינן רלוונטיות.
הטבלה הראשונה מספקת את הקשר בין הפלייליסטים לשירים, בעוד הטבלה השניה מוסיפה את שם הפלייליסט ולכן בחרתי רק את שם הפלייליסט מהטבלה השניה.

dim_customer

הטבלה נבנתה מתוך stg.customer כאשר בחרתי לרשום ידנית את העמודות ולא להשתמש בבחירה של הכל, משום שביצעתי שינוי בעמודות השם הפרטי ושם המשפחה ורציתי להימנע משמירה כפולה של הערכים המקוריים והמעודכנים.

השתמשתי בפונקציה initcap כדי להפוך את האות הראשונה בכל שם לאות גדולה, וב-split_part בכדי לחלץ מתוך כתובת האימייל את החלק שמופיע אחרי ה-'@' ובכך ליצור ממנו עמודת domain.

dim_employee

בטבלת העובדים בחרתי את כל עמודות employee והוספתי את שם המחלקה והתקציב מתוך department_budget באמצעות left join, כדי לשמור את כל העובדים גם אם אין התאמה למחלקה.
את שנות העבודה חישבתי באמצעות age ו-date_part, לפי ההפרש בין hiredate ל-last_update, מאחר שהנתונים לא מעידים שהעובד עדיין פעיל כיום.
בנוסף השתמשתי ב-split_part כדי לחלץ את הדומיין מכתובת האימייל.
כדי לזהות מנהלים השתמשתי ב-case אם employeeid מופיע בעמודת reportsto של עובד אחר, העובד סומן כ 1 אחרת 0, כלומר 1 הוא מנהל 0 איננו מנהל.

dim_track

בטבלת dim_track חיברתי את טבלת track לטבלאות
mediatype, artist, album and genre
באמצעות inner join, כדי להוסיף לכל track את שם האלבום, שם האמן, סוג המדיה וז'אנר.

בנוסף בדקתי את עמודות last_update בכל הטבלאות הרלוונטיות מכיוון שהפער בין זמן העדכון המוקדם ביותר למאוחר ביותר קטן מ- 6 שניות, החלטתי לשמור רק את עמודת last_update של טבלת track ולא להוסיף עמודות נוספות ללא ערך משמעותי.

את משך הtrack המרתי ממילישניות לשניות באמצעות חלוקה ב1000.
לאחר מכן יצרתי עמודת duration בפורמט של דקות שניות, לצורך זה השתמשתי ב-make_interval כדי ליצור ערך זמן מתוך מספר השניות, וב-to_char בכדי להציג אותו בפורמט הרצוי של mi:ss.

fact_invoice

בטבלת fact_invoice בחרתי לשמור את כל העמודות מטבלת invoice, כולל שדות כתובת החיוב.
לפני יצירת הטבלה השוותי בין כתובות החיוב שבטבלת invoice לבין כתובות הלקוחות שבטבלת customer.
השתמשתי ב- count distinct כדי לבדוק כמה כתובות ייחודיות קיימות בכל טבלה, לאחר מכן בexcept כדי לזהות כתובות שמופיעות בטבלה אחת ולא בשניה.

מכיוון שנמצאה כתובת חיוב נוספת שאינה מופיעה בטבלת customer, החלטתי לשמור גם את שדות כתובת החיוב בתוך fact_invice כדי לא לאבד מידע רלוונטי לעסקה.

fact_invoiceline

בטבלת fact_invoiceline בחרתי לשמור את כל העמודות מטבלת invoiceline, ובנוסף יצרתי את העמודה line_total.

לפני יצירת הטבלה בדקתי את הערך המקסימלי בעמודת quantity באמצעות MAX, כדי להבין את מבנה הנתונים ולוודא כיצד לחשב את סכום השורה.

את line_total חישבתי באמצעות הכפלת quantity ב-unitprice, כך שכל שורה בטבלה מציגה גם את הסכום הכולל של אותה שורת מכירה.

add primary keys and foreign key

לאחר יצירת טבלאות ה-dwh ביצעתי בדיקות תקינות כדי לוודא שהמפתחות שאבחר אכן מתאימים לשמש כמפתחות ראשיים. לצורך זה השתמשתי ב-count(*) כדי לבדוק את מספר הרשומות הכולל וב- count distinct כדי לבדוק את מספר הערכים הייחודיים בכל עמודת מפתח. בטבלת dim_currency בדקתי בנוסף שאין ערכי NULL בעמודת invoicedate.
לאחר הבדיקות הוספתי מפתחות ראשיים באמצעות alter table ו-add primary key. ברוב הטבלאות השתמשתי במפתח יחיד, ורק בטבלת dim_playlist השתמשתי במפתח מורכב של playlistid ו-trackid, מכיוון שהשילוב ביניהם מייצג באופן ייחודי את הקשר בין פלייליסט לשיר.
לאחר מכן הוספתי מפתחות זרים באמצעות alter table ו-add foreign key כדי להגדיר את הקשרים בין הטבלאות ולשמור על תקינות הקשרים בין הנתונים. בין היתר חיברתי את fact_invoice ל-dim_customer, את fact_invoiceline ל-fact_invoice ול-dim_track, את dim_customer ל-dim_employee ואת dim_playlist ל-dim_track.

important remark

במהלך בדיקת ערכי המדינות גיליתי שאותה מדינה מופיעה בשני שמות שונים: usa ו-united states. כדי למנוע פיצול של הנתונים ותוצאות לא עקביות בניתוחים, החלטתי לאחד את הערכים.
לצורך זה השתמשתי ב-update על טבלת fact_invoice ושיניתי את הערך usa ל-united states בעמודת billingcountry.

data analysis - sql

בחלק הזה התבקשתי לענות על שאלות ניתוח באמצעות sql.

אפרט את דרך החשיבה והפתרון שלי עבור כל שאלה.

שאלה 1:

בשאלה הראשונה נדרשתי למצוא את הפלייליסטים עם מספר השירים הגבוה והנמוך ביותר, ולחשב את ממוצע השירים לפלייליסט.
לפני הניתוח ביצעתי שתי שאילתות בדיקה כדי לבדוק אם קיימים כמה פלייליסטים עם אותו מספר שירים מקסימלי או מינימלי. מכיוון שנמצאו שוויונות, השתמשתי בפונקציה dense_rank כדי לתת דירוג זהה לפלייליסטים בעלי אותו מספר שירים.
באמצעות cte יצרתי שני שלבי חישוב: בראשון השתמשתי ב-count וב-group by כדי לספור את מספר השירים בכל פלייליסט. בשני השתמשתי ב-dense_rank עם order by בסדר יורד ועולה כדי לדרג את הפלייליסטים מהגדול לקטן ולהפך, וב-avg עם over כדי לחשב את ממוצע השירים בכלל הפלייליסטים.
לבסוף השתמשתי ב-case כדי לסמן את הפלייליסטים כבעלי מספר השירים הגבוה או הנמוך ביותר, וב-where כדי להציג רק את הפלייליסטים שקיבלו דירוג 1 באחד משני הכיוונים.

שאלה 2:

בשאלה השנייה נדרשתי לחלק את כלל השירים לארבע קבוצות לפי מספר המכירות שלהם:
שירים שלא נמכרו כלל, שירים שנמכרו 1–5 פעמים, 6–10 פעמים ויותר מ-10 פעמים.
לצורך הניתוח יצרתי שני שלבי cte. בראשון השתמשתי ב-left join כדי לחבר בין טבלת השירים לטבלת שורות המכירה, כך שגם שירים שלא נמכרו כלל ייכללו בתוצאה. לאחר מכן השתמשתי ב-count וב-group by כדי לחשב את מספר המכירות של כל שיר.
בשלב השני השתמשתי ב-case וב-between כדי לשייך כל שיר לקבוצת המכירות המתאימה. בחרתי בטווח 6–10 כדי למנוע חפיפה עם קבוצת 1–5.
לבסוף השתמשתי ב-count וב-group by כדי לספור כמה שירים נמצאים בכל קבוצה, וב-order by כדי להציג את הקבוצות לפי מספר השירים בסדר יורד.

שאלה 3:

בסעיף הראשון בדקתי מהן חמש המדינות עם סכום המכירות הגבוה ביותר וחמש המדינות עם סכום המכירות הנמוך ביותר. תחילה השתמשתי ב-distinct וב-count כדי לבדוק את המדינות הקיימות בנתונים.
לאחר מכן יצרתי cte שבו חישבתי את סך המכירות לכל מדינה באמצעות sum ו-group by. השתמשתי ב-order by וב-limit כדי לבחור את חמש המדינות המובילות ואת חמש המדינות האחרונות, וב-union all כדי לאחד את התוצאות.

בסעיף השני השתמשתי במספר שלבי cte כדי לנתח את המכירות לפי ז'אנרים בעשר המדינות שנבחרו. תחילה חיברתי את טבלאות החשבוניות, שורות המכירה והשירים באמצעות inner join, וחישבתי את סכום המכירות של כל ז'אנר בכל מדינה.
בהמשך השתמשתי ב-sum יחד עם partition by כדי לחשב את סך המכירות בכל מדינה, מבלי לאחד את שורות הז'אנרים. לאחר מכן חישבתי את אחוז המכירות של כל ז'אנר מתוך כלל המכירות במדינה, ועיגלתי לשתי ספרות אחרי הנקודה באמצעות round.

לבסוף השתמשתי ב-rank כדי לדרג את הז'אנרים בתוך כל מדינה לפי אחוז המכירות שלהם, וב-order by כדי להציג את התוצאות בצורה מסודרת.

שאלה 4:

בניתי את הניתוח באמצעות שלושה שלבי cte כדי לחשב את מספר הלקוחות, ממוצע ההזמנות ללקוח וממוצע ההכנסות ללקוח בכל מדינה.
בשלב הראשון השתמשתי ב-count distinct כדי לספור לקוחות ייחודיים בכל מדינה, ב-count כדי לספור את מספר ההזמנות וב-sum כדי לחשב את סך ההכנסות.
בנוסף, השתמשתי ב-case כדי להעביר מדינות שבהן יש לקוח אחד בלבד לקבוצה בשם other.
בשלב השני השתמשתי שוב ב-group by וב-sum כדי לאחד את כל המדינות שסווגו כ-other ולחשב את הנתונים הכוללים שלהן.
בשלב האחרון חישבתי את ממוצע ההזמנות ואת ממוצע ההכנסות ללקוח באמצעות חלוקת הסכומים במספר הלקוחות. השתמשתי ב-round כדי לעגל את התוצאות לשתי ספרות אחרי הנקודה.

שאלה 5:

בניתי את הניתוח באמצעות ארבעה שלבי cte כדי להציג את שנות העבודה של כל עובד, מספר הלקוחות הייחודיים שטיפל בהם בכל שנה ואת אחוז השינוי במכירות לעומת השנה הקודמת.
בשלב הראשון חיברתי את טבלאות העובדים, הלקוחות והחשבוניות באמצעות inner join. השתמשתי ב-concat כדי ליצור שם מלא לעובד וב-extract כדי להוציא את שנת המכירה מתוך תאריך החשבונית.
בשלב השני השתמשתי ב-count distinct כדי לספור את מספר הלקוחות הייחודיים של כל עובד בכל שנה, וב-sum כדי לחשב את סך המכירות השנתי שלו.
בשלב השלישי השתמשתי בפונקציה lag יחד עם partition by ו-order by כדי לקבל את סכום המכירות של השנה הקודמת עבור כל עובד בנפרד.

בשלב האחרון חישבתי את אחוז השינוי במכירות באמצעות ההפרש בין המכירות בשנה הנוכחית לשנה הקודמת, חלקי המכירות בשנה הקודמת, כפול 100.
השתמשתי ב-round כדי לעגל את התוצאה לשתי ספרות אחרי הנקודה.

שאלות 6, 7 ו-8: שאילתות נוספות

שאלה 6:

בניתי את הניתוח כדי לבדוק את עונתיות המכירות בעשר המדינות עם סך המכירות הגבוה ביותר. המטרה הייתה לזהות בכל מדינה את החודש החזק והחלש ביותר מבחינת מכירות, ולחשב את ההפרש ביניהם.
תחילה יצרתי cte שבו השתמשתי ב-extract כדי להוציא את החודש מתאריך החשבונית, וב-sum ו-group by כדי לחשב את סך המכירות בכל חודש, ללא הפרדה בין השנים. בנוסף, השתמשתי ב-sum יחד עם partition by כדי לחשב את סך המכירות הכולל של כל מדינה.
לאחר מכן השתמשתי ב-distinct, ב-order by וב-limit כדי לבחור את עשר המדינות המובילות במכירות, וב-inner join כדי להמשיך את הניתוח רק עבור המדינות שנבחרו.
בשלב הבא השתמשתי ב-rank יחד עם partition by כדי לדרג את החודשים בכל מדינה בשני כיוונים: מהחודש עם המכירות הגבוהות ביותר לנמוכות ביותר, ולהפך.
לאחר מכן סיננתי רק את החודשים שקיבלו דירוג 1 באחד הכיוונים.
לבסוף השתמשתי ב-case יחד עם max כדי להציג את החודש הטוב ביותר מבחינת סכום מכירות, החודש החלש ביותר מאותה בחינה וסכומי המכירות שלהם בשורה אחת לכל מדינה. בנוסף, חישבתי את ההפרש בין סכומי המכירות של שני החודשים.

מטרת הניתוח היא לזהות דפוסים עונתיים אפשריים ולהבין באילו חודשים המכירות נוטות להיות חזקות או חלשות יותר בכל מדינה. המידע יכול לסייע בקבלת החלטות עסקיות, כמו תכנון מבצעים, פעילויות שיווק והיערכות לתקופות שבהן צפויות מכירות גבוהות או נמוכות יותר. חשוב לציין שהניתוח מצביע על הבדלים בין חודשים, אך אינו מוכיח לבדו שקיימת עונתיות קבועה שחוזרת בכל שנה.

<u>שאלה 7:</u>

בניתי את הניתוח כדי לבדוק עד כמה המכירות בכל מדינה תלויות במספר קטן של לקוחות. המטרה הייתה לבדוק איזה אחוז מסך המכירות בכל מדינה מגיע משלושת הלקוחות המובילים שלה, ולסווג את רמת הריכוזיות לנמוכה, בינונית או גבוהה.

תחילה בדקתי את מספר הלקוחות הייחודיים בכל מדינה באמצעות count ו-distinct.
לאחר מכן יצרתי cte שבו חישבתי את סך המכירות ואת מספר הלקוחות הייחודיים בכל מדינה, והשתמשתי ב-having כדי לכלול רק מדינות עם לפחות 10 לקוחות.
בחרתי לעשות זאת כדי שההשוואה תהיה משמעותית יותר ולא תושפע ממדינות עם מספר קטן מאוד של לקוחות.
בשלב הבא השתמשתי ב-inner join כדי לחבר את המדינות שנבחרו לטבלת החשבוניות, וחישבתי את סך המכירות של כל לקוח בכל מדינה.
לאחר מכן השתמשתי ב-row_number יחד עם partition by כדי לדרג את הלקוחות בכל מדינה לפי סכום המכירות שלהם, מהגבוה לנמוך. בחרתי להשתמש ב-row_number כדי לקבל בדיוק שלושה לקוחות מכל מדינה, גם במקרים שבהם כמה לקוחות הגיעו לאותו סכום מכירות.
לאחר שבחרתי את שלושת הלקוחות המובילים, השתמשתי ב-sum יחד עם partition by כדי לחשב את סכום המכירות הכולל שלהם בכל מדינה. לאחר מכן חישבתי איזה אחוז הם מהווים מסך המכירות של אותה מדינה, והשתמשתי ב-distinct כדי להציג כל מדינה פעם אחת בלבד.

לבסוף השתמשתי ב-case כדי לחלק את המדינות לשלוש רמות ריכוזיות: ריכוזיות נמוכה כאשר שלושת הלקוחות אחראים לפחות מ-25% מהמכירות,
ריכוזיות בינונית כאשר האחוז הוא בין 25% לפחות מ-50%,
וריכוזיות גבוהה כאשר האחוז הוא 50% ומעלה.

מטרת הניתוח היא לזהות מדינות שבהן חלק גדול מהמכירות מגיע ממספר קטן של לקוחות. ריכוזיות גבוהה יכולה להצביע על תלות בלקוחות מרכזיים ועל סיכון במקרה שאחד מהם יפסיק לרכוש. לעומת זאת, ריכוזיות נמוכה יכולה להעיד על פיזור רחב יותר של המכירות בין הלקוחות.
המידע יכול לעזור לחברה להבין באילו מדינות כדאי להשקיע בשימור לקוחות מרכזיים, ובאילו מדינות יש צורך להרחיב את בסיס הלקוחות כדי להפחית את התלות במספר מצומצם של לקוחות.

שאלה 8:

מטרת הניתוח הייתה לבדוק את התנהגות הרכישה של הלקוחות ולהבין עד כמה לקוחות חוזרים משמעותיים להכנסות החברה. לשם כך חילקתי את הלקוחות לשלוש קבוצות לפי מספר ההזמנות שביצעו: לקוחות שביצעו הזמנה אחת, לקוחות שביצעו 2–3 הזמנות ולקוחות שביצעו 4 הזמנות ומעלה.

תחילה יצרתי cte בשם customer_summary, שבו חישבתי עבור כל לקוח את מספר ההזמנות הייחודיות שביצע באמצעות count ו-distinct, ואת סך ההכנסות ממנו באמצעות sum. לאחר מכן יצרתי cte נוסף בשם customer_groups, שבו השתמשתי ב-case כדי לשייך כל לקוח לאחת משלוש הקבוצות בהתאם למספר ההזמנות שלו.

לבסוף קיבצתי את הנתונים לפי קבוצות הלקוחות וחישבתי עבור כל קבוצה את מספר הלקוחות, מספר ההזמנות הכולל, ממוצע ההזמנות ללקוח, סך ההכנסות וממוצע ההכנסות ללקוח. השתמשתי גם ב-avg לחישוב הממוצעים וב-round כדי להציג את התוצאות עם שתי ספרות אחרי הנקודה.

מהניתוח עולה שבקבוצות שבהן הלקוחות מבצעים יותר הזמנות, גם מספר הלקוחות וגם סך ההכנסות גבוהים יותר. המשמעות היא שלקוחות רבים אינם מסתפקים ברכישה אחת, אלא חוזרים ומבצעים רכישות נוספות. בנוסף, לקוחות חוזרים מייצרים הכנסות משמעותיות לחברה, מה שמדגיש את החשיבות שלהם לפעילות העסקית. מטרת הניתוח היא לעזור לחברה להבין את דפוסי הרכישה של הלקוחות, לזהות את החשיבות של רכישות חוזרות ולבחון כיצד ניתן לעודד לקוחות להמשיך לרכוש גם בעתיד.

data analysis - python

שאלה 1:

בשאלה הראשונה נדרשתי להציג את חמשת האמנים עם מספר האלבומים הגבוה ביותר, חמשת האמנים עם מספר השירים הגבוה ביותר וחמשת הז'אנרים עם מספר השירים הגבוה ביותר, בשלושה גרפים נפרדים בתוך אותה תצוגה.
תחילה שלפתי את הנתונים הרלוונטיים מטבלת dim_track באמצעות read_sql.
לאחר מכן השתמשתי ב-groupby כדי לקבץ את הנתונים לפי אמנים וז'אנרים. עבור מספר האלבומים השתמשתי ב-nunique כדי לספור אלבומים ייחודיים ולמנוע ספירה חוזרת של אותו אלבום, ועבור השירים השתמשתי ב-count.
בהמשך השתמשתי ב-sort_values כדי למיין את התוצאות בסדר יורד וב-head(5) כדי לבחור את חמשת המובילים בכל קטגוריה. לבסוף השתמשתי ב-subplots כדי ליצור שלושה גרפי עמודות באותה תצוגה, וב-bar_label כדי להציג את הערכים מעל העמודות.

מטרת הניתוח הייתה להבין אילו אמנים וז'אנרים תופסים את החלק הגדול ביותר בקטלוג השירים והאלבומים של החברה. מידע זה יכול לסייע בהבנת הרכב התוכן הקיים, אך אינו מעיד בהכרח על היקף המכירות של אותם אמנים וז'אנרים.

<u>שאלה 2:</u>

בשאלה השנייה נדרשתי לזהות את חמשת הלקוחות שרכשו בסכומים הגבוהים ביותר, ולהציג את סכומי הרכישות שלהם בדולרים ובשקלים.
תחילה שלפתי באמצעות read_sql נתונים מטבלאות החשבוניות, הלקוחות ושערי המטבע, תוך חיבור הטבלאות לפי מזהה הלקוח ותאריך החשבונית. את סכום הרכישה בשקלים חישבתי באמצעות הכפלת הסכום בדולרים בשער ההמרה המתאים לאותו תאריך.
לאחר מכן יצרתי עמודה של שם מלא באמצעות חיבור השם הפרטי ושם המשפחה.
השתמשתי ב-round לעיגול שערי ההמרה והסכומים בשקלים לשתי ספרות אחרי הנקודה.
בהמשך השתמשתי ב-groupby וב-sum כדי לחשב את סך הרכישות של כל לקוח בשני המטבעות. מיינתי את הלקוחות באמצעות sort_values לפי הסכום בדולרים והשתמשתי ב-head(5) כדי לבחור את חמשת המובילים.
לבסוף יצרתי שני גרפי עמודות באמצעות subplots, אחד בדולרים ואחד בשקלים, והוספתי את סכומי הרכישות מעל העמודות.

מטרת הניתוח הייתה לזהות את הלקוחות שמייצרים את ההכנסות הגבוהות ביותר לחברה. מידע זה יכול לסייע בזיהוי לקוחות מרכזיים ובתכנון פעולות לשימורם.

שאלה 3:

בשאלה השלישית נדרשתי להציג את סכום המכירות בכל חודש לאורך כל שנות הפעילות, כדי לבחון כיצד המכירות משתנות לאורך זמן.
תחילה שלפתי באמצעות read_sql את סכומי המכירות החודשיים מטבלת fact_invoice. בשאילתה השתמשתי ב-extract כדי להפריד את השנה והחודש מתוך תאריך החשבונית, וב-sum ו-group by כדי לחשב את סך המכירות עבור כל חודש בכל שנה.
לאחר מכן השתמשתי ב-astype כדי להמיר את ערכי השנה והחודש למחרוזות, וחיברתי אותם לעמודה חדשה בשם year_month, כדי ליצור ציר זמן מסודר לגרף.

לבסוף יצרתי גרף קווי באמצעות plot, והוספתי נקודות לכל חודש באמצעות marker. השתמשתי ב-xticks כדי להציג את החודשים לאורך ציר הזמן וב-tight_layout כדי לשפר את התצוגה.

מטרת הניתוח הייתה לזהות מגמות ושינויים בהיקף המכירות לאורך השנים, לאתר חודשים חזקים וחלשים ולבחון האם קיימים דפוסים שיכולים לסייע בתכנון הפעילות העסקית.

<u>שאלה 4:</u>

בשאלה הרביעית בדקתי האם קיים קשר בין אורך השיר לבין סכום המכירות שלו, במטרה להבין האם משך השיר עשוי להשפיע על הביצועים המסחריים שלו.

תחילה שלפתי את נתוני השירים והמכירות באמצעות read_sql. השתמשתי ב-left join כדי לכלול גם שירים שלא נמכרו, וב-sum כדי לחשב את סכום המכירות הכולל לכל שיר. בנוסף, השתמשתי ב-coalesce כדי להחליף ערכי null בסכום המכירות באפס, וב-round כדי להמיר את אורך השירים משניות לדקות ולעגל לשתי ספרות אחרי הנקודה.
לאחר מכן יצרתי גרף פיזור באמצעות plot.scatter, כאשר ציר אחד מציג את אורך השיר בדקות והציר השני את סכום המכירות שלו.

מהניתוח עלה שקיים קשר חיובי חלש מאוד בין אורך השיר לבין המכירות, עם מקדם קורלציה של כ-0.14. ניתן לראות ששירים קצרים וארוכים יכולים להגיע לסכומי מכירות שונים, ללא מגמת עלייה או ירידה ברורה.
לכן, על בסיס הנתונים שנבדקו, אורך השיר לבדו אינו נראה כגורם משמעותי להסבר השונות במכירות.

<u>שאלה 5:</u>

בשאלה החמישית נדרשתי לבנות מערכת המלצות שתציע לכל לקוח שישה שירים לרכישה, שלושה מכל אחד משני הז'אנרים המועדפים עליו, תוך התחשבות בפופולריות השירים ובכך שהלקוח עדיין לא רכש אותם.

תחילה שלפתי באמצעות read_sql את נתוני הרכישות, השירים והז'אנרים מתוך טבלאות ה-dwh. לאחר מכן השתמשתי ב-groupby וב-count כדי לספור כמה שירים רכש כל לקוח מכל ז'אנר. באמצעות sort_values ו-head(2) בחרתי את שני הז'אנרים המובילים של כל לקוח לפי מספר הרכישות.
בשלב הבא חישבתי את מספר המכירות של כל שיר באמצעות groupby ו-count, כדי לזהות את השירים הפופולריים ביותר. לאחר מכן השתמשתי ב-merge כדי לשלב בין הז'אנרים המועדפים על הלקוחות לבין השירים המשתייכים אליהם.
כדי למנוע המלצה על שירים שכבר נרכשו, יצרתי טבלה של רכישות ייחודיות באמצעות drop_duplicates. חיברתי אותה לטבלת ההמלצות באמצעות merge עם left join ו-indicator, שאפשרו לי לזהות ולהסיר שירים שכבר נרכשו על ידי אותו לקוח.

לבסוף מיינתי את השירים לפי מספר המכירות שלהם והשתמשתי ב-groupby וב-head(3) כדי לבחור את שלושת השירים הפופולריים ביותר מכל ז'אנר מועדף עבור כל לקוח.
מטרת הניתוח הייתה ליצור המלצות אישיות המבוססות על הרגלי הרכישה של הלקוחות ועל פופולריות השירים. מערכת כזו יכולה לסייע לחברה להציע תוכן רלוונטי יותר ולעודד רכישות נוספות. עבור לקוחות שרכשו שירים מז'אנר אחד בלבד, בחרתי להמליץ רק על שירים מאותו ז'אנר ולא להניח שקיים ז'אנר מועדף נוסף.

שאלת python נוספת:

שאלה 6:

מטרת הניתוח הייתה לבדוק האם הז'אנרים המובילים במכירות בחודשים ינואר ופברואר יכולים לשמש כאינדיקציה להעדפות הלקוחות בהמשך השנה. לצורך כך בחרתי להתמקד בעשר המדינות עם מספר ההזמנות הגבוה ביותר בשנת 2021, ולהשוות בין שלושת הז'אנרים המובילים בתחילת השנה לבין שלושת הז'אנרים המובילים בחודשים מרץ עד דצמבר.

תחילה שלפתי באמצעות read_sql את נתוני החשבוניות, המדינות, הז'אנרים והשירים שנרכשו. לאחר שבדקתי שעמודת התאריך שמורה בפורמט מתאים, השתמשתי ב-dt.year כדי לסנן את הנתונים לשנת 2021.
לאחר מכן השתמשתי ב-groupby וב-nunique כדי לספור את מספר ההזמנות הייחודיות בכל מדינה. מיינתי את התוצאות באמצעות sort_values ובחרתי את עשר המדינות המובילות באמצעות head(10). לאחר מכן השתמשתי ב-isin כדי להשאיר רק את נתוני המכירות של המדינות שנבחרו.
בשלב הבא חילקתי את הנתונים לשתי תקופות באמצעות dt.month: ינואר–פברואר ומרץ–דצמבר. עבור כל תקופה השתמשתי ב-groupby וב-count כדי לספור את מספר השירים שנמכרו מכל ז'אנר בכל מדינה. לאחר מיון התוצאות בחרתי באמצעות head3 את שלושת הז'אנרים המובילים בכל מדינה ובכל תקופה.
בהמשך השתמשתי ב-merge מסוג left כדי להשוות בין הז'אנרים המובילים בשתי התקופות. באמצעות notna בדקתי אילו ז'אנרים שהיו בשלישייה המובילה בתחילת השנה נשארו בשלישייה המובילה גם בהמשך השנה.
לאחר מכן השתמשתי ב-mean כדי לחשב את אחוז הז'אנרים שנשארו בשלישייה המובילה, וב-groupby כדי לחשב את האחוז לכל מדינה בנפרד. לבסוף הצגתי את התוצאות בגרף עמודות באמצעות plot.bar.

מהניתוח עלה כי 80% מהז'אנרים שהיו בשלישייה המובילה בינואר ובפברואר נשארו בשלישייה המובילה גם בחודשים מרץ עד דצמבר. בארבע מדינות שיעור ההתאמה היה 100%, ובשש המדינות האחרות הוא עמד על 66.67%.
התוצאות מצביעות על יציבות יחסית בהעדפות הז'אנרים במהלך שנת 2021, ומציעות כי נתוני המכירות בתחילת השנה עשויים לשמש כאינדיקציה מוקדמת להמשך השנה. מידע זה יכול לסייע לחברה בתכנון פעילויות שיווק וקידום של ז'אנרים פופולריים במדינות שונות. עם זאת, כדי לקבוע שמדובר בדפוס קבוע, יש לבדוק את התוצאות גם בשנים נוספות.